Relatório de evolução do projeto

EnergiaLar | Sprint 4 | FIAP x GoodWe Brasil | Prompt and Artificial Intelligence | 2026.2

Relatório baseado em fallback manual; limitações técnicas e evidências disponíveis são declaradas de forma explícita.

1. Resumo da evolução

A Sprint 3 do EnergiaLar manteve uma cadeia conversacional LCEL com memória por sessão, validação Pydantic v2, prompts externos e avaliação de modelos. A Sprint 4 preserva essa base e acrescenta uma camada documental RAG com ChromaDB persistente, prompts RAG versionados, citações visíveis, interface Streamlit e avaliação de fidelidade e relevância.

O RAG não substitui o assistente conversacional da Sprint 3 nem cria ligação com um carregador físico. Ele acrescenta uma camada documental para responder com base em fontes recuperadas, citações visíveis e recusa quando faltar evidência.

Validação funcional registrada no workspace Windows: 48 testes aprovados após correções Q04/Q05. A v1 foi pontuada manualmente nos oito casos em 23/10/2026 (run_id 20261023_003912_871419): contexto médio 0,857 (n=7; revisão manual dos chunks completos), faithfulness/relevância 0,938/0,938, citações 7/7 e estrutura válida 8/8. V1→v2 caiu 0,031; v2→v3 subiu +0,094 para 1,000/1,000. Scores são fallback manual, não RAGAS.

Referência técnica histórica da versão pública Sprint 3: nos cinco casos happy-path comparáveis, o arquivo sprint3_results.json registra 192,6 tokens médios, 9,356 s de latência média e saída estruturada válida em 5/5 casos. Os campos de avaliação manual continuam pendentes; esses valores não são scores de qualidade. A comparação da Sprint 2 registrava cinco casos como Adequada, sem tokens/latência.

2. Pipeline RAG

Documentos em data/knowledge_base -> PyMuPDFLoader para PDFs / TextLoader para Markdown e TXT / CSVLoader para CSV -> filtro heurístico de linhas maliciosas -> RecursiveCharacterTextSplitter -> nomic-embed-text via Ollama local (desvio literal Cloud documentado) -> ChromaDB persistente -> retriever top-k -> prompt RAG versionado v1/v2/v3 -> gemma4:31b no Ollama Cloud -> JSON validado por Pydantic v2 -> resposta e fontes no Streamlit.

Configuração usada: chunk_size=800 caracteres, overlap=120, top_k=8, limiar de relevância=0,15, temperature=0, top_p=0,9 e max_tokens=600. O limiar é configurável e precisa ser validado pelo eval set; não é uma garantia universal.

3. Base de conhecimento e trade-offs

O pacote analisado inclui os dois PDFs oficiais GoodWe, além de folha de dados, FAQ, protocolo-modelo de condomínio não normativo, leis paulistas com links oficiais, preços didáticos simulados e componentes tarifários publicados pela Enel SP (vigência indicada desde 04/07/2026, não equivalem à fatura total). O manual continua obrigatório para liberar a indexação. O manual HCA G2 em inglês e a lista oficial de compatibilidade estão presentes; confirmar que o índice Chroma foi reconstruído após sua inclusão.

O chunk de 800 caracteres procura preservar uma unidade curta de informação; overlap de 120 preserva continuidade em limites de blocos. Aumentar chunk pode juntar assuntos diferentes; diminuir demais pode separar ressalvas de segurança. A escolha inicial deve ser validada por fidelidade e relevância medidas, não apenas por respostas fluentes.

4. Segurança e grounding

Os prompts v2/v3 distinguem explicitamente contexto de instruções, mandam ignorar tentativas de prompt injection contidas nos documentos, pedem recusa fora do escopo, exigem o contrato JSON de Pydantic v2 e proíbem inventar especificações, compatibilidades, tarifas e dimensionamentos elétricos. O carregador filtra padrões conhecidos de instruções maliciosas e a saída tem um bloqueio heurístico simples para padrões semelhantes a credenciais. Esses mecanismos reduzem riscos conhecidos, mas não são uma prova formal de segurança.

Toda consulta com contexto útil mostra nome da fonte e página do PDF, quando disponível. Se nenhum chunk ultrapassa o limiar, a aplicação responde com uma recusa e informa que a base não deu suporte suficiente.

5. Problemas encontrados e soluções

Problema	Decisão tomada e motivo
Base da Sprint 3 era conversacional, sem busca vetorial	Preservar LCEL, prompts externos, memória por sessão e o schema Pydantic; acrescentar uma camada documental separada para RAG.
Risco de o modelo inventar dados ou seguir texto malicioso	Prompt v2 com contexto não confiável, filtro inicial de linhas suspeitas, recusa por falta de evidência e caso de teste de injection.
Tarifas e regras do condomínio podem ser interpretadas como oficiais	Separar referência oficial de exemplo simulado e rotular explicitamente o protocolo de condomínio como orientativo.
Q04 omitia o art. 2º da lei estadual em uma pergunta ampla	Busca complementar dirigida ao art. 2º, validação dos termos artigo/capacidade mínima/instalação futura e regra no prompt v3 para cobrir o ponto quando está no contexto.

6. Tabela de comparativo antes/depois

A v1 foi pontuada nos oito casos; a rubrica manual de 0-1 não é RAGAS. Q04 e Q05 receberam 0,75 em faithfulness/relevância por omissões secundárias; Q07 recebeu 1,00/1,00 conforme a rubrica de segurança. A auditoria dos chunks completos pontuou contexto Q01=0,75, Q02=1,00, Q03=1,00, Q04=1,00, Q05=0,75, Q07=0,75 e Q08=0,75; Q06 é N/A. A média do contexto é 0,857; há ruído de chunks adicionais, e a nota não é RAGAS.

Indicador	Sprints 1/2 (versão original)	Sprint 4 v1	Sprint 4 v2	Sprint 4 v3
Arquitetura	Versão original sem RAG vetorial; detalhes históricos limitados.	RAG separado; Chroma + UI.	Mesmo pipeline; prompt atualizado.	Mesmo pipeline; iteração extra.
Grounding/citação	Citação documental por chunk/página não registrada.	Cobertura 100% (7/7).	Cobertura 100% (7/7).	Cobertura 100% (7/7).
Qualidade do contexto (0-1)	N/A: sem RAG.	0.857 (n=7; auditado)	0.857 (n=7; mesmos chunks)	0.857 (n=7; mesmos chunks)
Faithfulness (0-1)	N/A: sem RAG.	0.938 (n=8)	0.906 (n=8)	1.000 (n=8)
Answer relevancy (0-1)	N/A: sem RAG.	0.938 (n=8)	0.906 (n=8)	1.000 (n=8)
Citações presentes (%)	Não coletado no baseline.	100% (n=7)	100% (n=7)	100% (n=7)
Delta v2 - v1	N/A	N/A	Faith=-0.031; Relev.=-0.031; Contexto=0.000	N/A
Delta v3 - v2	N/A	N/A	N/A	Faith=0.094; Relev.=0.094; Contexto=0.000

Deltas medidos: v1→v2 = -0,031 em faithfulness/relevância e 0,000 em contexto; v2→v3 = +0,094 em faithfulness/relevância e 0,000 em contexto. A média do contexto fica em 0,857 (n=7) nas três versões, pois os chunks recuperados por pergunta são iguais nos registros avaliados.

7. Comparação de modelos no prompt v3

Modelo (v3)	Faithfulness	Answer relevancy	Latência (s)	Casos	Falhas JSON
gemma4:31b	1.000	1.000	3.78	8	0
gpt-oss:20b	0.750	0.750	6.92	8	2

A rubrica manual de 0 a 1 está em evals/manual_rubric.md. As notas são fallback manual, não RAGAS. O GPT-OSS teve cinco falhas JSON no total da matriz (3 em v2, 2 em v3); as falhas foram mantidas no agregado.

8. Parâmetros e reprodutibilidade

Item	Configuração registrada
Embeddings Windows	nomic-embed-text em Ollama local; desvio literal de Ollama Cloud registrado
Alternativa Colab	nomic-ai/nomic-embed-text-v1.5 executado no runtime cloud do Colab; chat no Ollama Cloud; não é endpoint de embeddings Ollama Cloud
Modelos comparados	gemma4:31b (recomendado, prompt v3) e gpt-oss:20b (5 falhas JSON em 16 saídas)
temperature / top_p / max_tokens	0.0 / 0.9 / 600
Recuperação	top_k=8; limiar inicial=0.15; expansão dirigida da evidência legal para Q04
Chunking	800 caracteres; overlap=120
Reprodução	`python -m src.rag.build_index --force`; `python -m evals.run_eval --mode iterations --model gemma4:31b --interactive`; `python -m evals.run_eval --mode models --models gemma4:31b gpt-oss:20b --interactive`

A configuração funcional mantém `gemma4:31b` no chat Cloud e usa `nomic-embed-text` local para embeddings, pois o endpoint Cloud retornou 401. Isso diverge literalmente do requisito de embeddings Cloud e está documentado; não declarar conformidade integral.

9. Equipe e divisão de trabalho

A implementação e a avaliação documentadas nesta versão foram executadas por Kaique. Para manter o registro honesto, as atribuições dos demais integrantes aparecem como revisões propostas e pendentes, não como trabalho concluído.

Integrante	RM	Contribuição confirmada / revisão proposta
Renan Eskildssen	571097	Contribuição nesta versão não confirmada; revisão de proveniência documental ainda não confirmada.
Lucas Barros	571528	Contribuição nesta versão não confirmada; revisão da comparação de modelos e parâmetros pendente.
Kaique Da Silva Assis	572718	Implementação RAG, Q04/Q05, prompts, testes, avaliação manual e documentação.
Andre Debiazzi Baldi Negrini	569062	Contribuição nesta versão não confirmada; revisão de guardrails e prompt injection pendente.
Vinicius Cristal de Oliveira	572049	Contribuição nesta versão não confirmada; teste final da interface/citações pendente.

A v1 foi pontuada em Q01-Q08 e incorporada ao comparativo: v1=0,938, v2=0,906 e v3=1,000 nas duas métricas de resposta. O contexto foi auditado dos chunks integrais: 0,857 nos sete casos recuperáveis (Q06=N/A). O notebook Colab usa Nomic Embed Text v1.5 no runtime hospedado do Colab; não é o endpoint gerenciado de embeddings Ollama Cloud.

Fontes oficiais e rastreabilidade, revisão documental em 23/10/2026: GoodWe Brasil - downloads HCA G2 (https://br.goodwe.com/download-hca-g2-series) e ficha técnica (https://br.goodwe.com/Api/downloadFile?id=3931&mid=60&type=1); ALESP, Lei 18.403/2026 (https://al.sp.gov.br/repositorio/legislacao/lei/2026/lei-18403-18.02.2026.html); Prefeitura de São Paulo, Lei 17.336/2020 (https://legislacao.prefeitura.sp.gov.br/lei-17336-de-30-de-marco-de-2020); Enel SP, tarifa vigente desde 04/07/2026 (https://www.enel.com.br/pt-saopaulo/Para_Voce/tarifa-energia-eletrica.html); Ollama Cloud e API de embeddings (https://docs.ollama.com/cloud; https://docs.ollama.com/api/embed; https://github.com/ollama/ollama/issues/14496; https://github.com/ollama/ollama/issues/17129); registro oficial de gpt-oss:20b e preços (https://ollama.com/library/gpt-oss%3A20b-cloud). Referências adicionais e escopo das afirmações estão em docs/REVISAO_FONTES_EXTERNAS.md. Valores didáticos não são tarifas oficiais.